

浙江大学

本科实验报告

课程名称： 信号与系统

姓 名：

学 院： 信息与工程学院

系：

专 业： 信息工程

学 号：

指导教师： 王作佳

2026 年 6 月 13 日

浙江大学课程设计报告

课程名称： 信号与系统 指导老师： 王作佳 成绩： _____
实验名称： 课题 E： 简单语音信号识别

一、实验目的

- 将《信号与系统》课程中所学的“信号的脉冲分解”、“非周期信号傅里叶变换（FT）”以及“离散信号频域分析”等理论知识，切实应用到真实的语音信号处理中；
- 深入理解并应用动态时间规整（DTW）算法和梅尔倒谱系数（MFCC）特征提取技术，实现对简单语音信号的高精度特征匹配与模式识别；
- 学习使用 MATLAB 进行底层信号处理、GUI 界面开发，提升解决实际工程中 bug 的综合工程开发能力；

二、实验任务与要求

- 自行确定一个小型语音识别任务，例如识别 3 至 5 句固定短语或若干个数字；
- 收集并整理参考音频数据与测试音频数据，可自行录音，也可使用公开数据集中的一部分样本；
- 对语音信号进行预处理，例如分帧、去静音、归一化、特征提取等；
- 使用 DTW（Dynamic Time Warping）或其他合适方法完成匹配与识别；
- 给出识别结果、正确率或距离比较结果，并分析算法效果与局限性；

三、实验原理

语音信号本质上是一维的时变非平稳随机信号。直接在时域进行波形匹配不仅受限于加性噪声，更极易受到说话人语速变化的严重干扰。因此，本实验的核心在于从时域波形中提取反映声学本质的频域特征，并利用动态规划消除时序畸变。

（一）语音信号的短时分析与预处理

语音信号在宏观尺度上非平稳，但在 10 ~ 30 ms 的短时窗口内发声器官的物理形状基本稳定，可近似视为平稳信号。

1. 预加重

补偿语音信号高频能量在空气传播和生理发声中的衰减，展平频谱。信号通过一阶高通滤波器：

$$s'(n) = s(n) - \mu s(n-1)$$

人类在发声时，由于嘴唇辐射和声道的生理特性，语音信号的高频能量会随着频率的升高而迅速衰减（大约每倍频程下降 6dB）。如果不加处理，高频部分的有用信息（比如很多辅音的特征）就会非常微弱，很容易被低频能量和噪声淹没。

预加重本质上就是一个一阶高通滤波器。它的作用就是“抑制低频、拉高高频”，强行把原本左高右低的倾斜频谱给“展平”，为后续的 FFT 和特征提取铺路。经过预加重把频谱展平后，再去进行分帧、加汉明窗、FFT，高频区域的共振峰（反映发音细节的关键特征）就

能在频谱上被清晰地凸显出来。同时，这也平衡了信号的动态范围，提高了数值计算的精度。

2. 分帧与加窗

引入帧长 $T = 25\text{ms}$ 的短时窗进行信号截断。为抑制时域截断产生的吉布斯现象与频谱泄漏，对每一帧信号乘以汉明窗：

$$w(n) = 0.54 - 0.46\cos(\frac{2\pi n}{N-1})$$

当把一段长语音切分成 25ms 的短帧时，如果在数学上什么都不做，就等同于给信号乘了一个矩形窗。这会导致截断后的语音波形在起始点和终止点发生突变。

汉明窗是一条钟形曲线。信号乘以汉明窗后，帧的首尾两端会平滑地衰减到接近 0。这样，无论怎么截断，信号两端看起来都是连续的。

快速傅里叶变换（FFT）隐含了一个数学假设：被变换的信号是无限周期循环的。如果直接对矩形窗截断的帧做 FFT，由于首尾突变，在频域上会产生高频振荡，它会导致原本集中的主频能量大量泄漏到旁边的频率中，使得强音完全掩盖住相邻的弱音。

经过汉明窗平滑后的信号在进行 FFT 时，频域的旁瓣能量会被极大地压低。矩形窗的第一旁瓣衰减只有 -13dB ，而汉明窗可以达到 -43dB 。这使得频谱能量高度集中在主频附近。

除了汉明窗，还有汉宁窗、布莱克曼窗等，在汉明窗的系数配比下，窗函数的频谱刚好能够让最大的几个旁瓣发生相位抵消。

相比于汉宁窗（两端完全衰减到 0，旁瓣衰减快但主瓣宽），汉明窗两端衰减到 0.08 左右，它的主瓣宽度和最大旁瓣高度之间取得了一个平衡。

如果不加汉明窗，提取出的 MFCC 特征会被截断噪声严重污染，DTW 算法在匹配时就会受到极大干扰。

（二）快速傅里叶变换（FFT）与功率谱

FFT 是离散傅里叶变换（DFT）的快速计算算法，将时域信号转换到频域：

$$X(k) = \sum_{n=0}^{N-1} x(n)e^{-j\frac{2\pi n k}{N-1}}, 0 \leq k \leq N-1$$

对加窗后的各帧信号进行 N 点快速傅里叶变换得到频谱，并取模平方得到离散功率谱密度估计 $P(k) = \frac{1}{N} |X(k)|^2$

（三）梅尔倒谱分析（MFCC）特征提取

MFCC 提取精准模拟了人耳低频敏感、高频迟钝的生理机制：

梅尔三角滤波器组：物理线性频率 f 与梅尔频率 f_{mel} 的非线性映射关系为：

$$f_{\text{mel}}(f) = 2595 \times \log_{10}(1 + \frac{f}{700})$$

将功率谱 $P(k)$ 通过一组等梅尔间隔的三角形带通滤波器组进行平滑压缩。

对滤波器组输出的能量谱取自然对数后，通过 DCT 进行正交变换映射到倒谱域。此举在物理上将“声道包络信息”与“基音激励信息”分离，最终仅提取前 13 阶低频系数作为系统特征。

本公式由声学泰斗 Douglas O'Shaughnessy 在 1987 年的权威著作中首次定调的标准格式，后来成为了语音识别工业界最正统的“原版公式”。也可表述为

$$f_{\text{mel}}(f) = 1127 \ln(1 + \frac{f}{700})$$

1. 频域的必要性

哪怕是同一个人、连续两次说同一个词，每次的起始点、语速、乃至每次声带振动的相位都不可能完全一样。在时域上，两个听起来一模一样的声音，相位相差 180 度时，波形长得完全相反，直接相减误差会极大。因此，我们必须把信号通过 FFT 转换到频域，因为频谱只看频率能量，天然忽略了相位的干扰。

2. 不直接用 FFT 的频谱的原因

直接把 FFT 算出来的几百个点作为特征不可行，原因有二：

(1) 数据维度太大

512 点的 FFT 会产生 257 个有效频点，数据量太大，计算 DTW 时会慢到死机。

(2) 不符合人耳生理构造

FFT 的频率分布是线性的（比如 100Hz 到 200Hz 的间距，和 8000Hz 到 8100Hz 的间距在 FFT 看来是一样的）。但人类耳蜗的基底膜像一个非线性的对数渐变滤波器，对低频极其敏感（能轻易分辨 100Hz 和 200Hz 的音调），但对高频迟钝（很难分辨 8000Hz 和 8100Hz）。

所以需要梅尔滤波器组，它在低频布置得极其密集，高频布置得很稀疏，强行把机器的线性频谱“扭曲”成了人耳的听觉频谱，并且把 257 个点降维压缩成了 20 个梅尔频带能量。

3. 取对数

人耳对声音大小（响度）的感知也是非线性的，人类对能量的感知是对数关系。所以要取 $\log$ ：对梅尔能量取对数，不仅完美模拟了人耳的响度感知，还能极大程度地抑制过大音量带来的数值畸变。

4. 离散余弦变换（DCT）

在语音发声的物理模型中，我们发出的声音 $S(t)$ ，实际上是声带的激励脉冲 $E(t)$ 与声道的冲击响应 $V(t)$ 的卷积： $S(t) = E(t) * V(t)$

声带激励 $E(t)$ 决定了声音的高低，反映的是“是谁在说话”；


声道形状 $V(t)$ 决定了共振峰，反映的是“说了什么字”。

在语音识别中，我们只关心内容而不是音色。但在时域里，卷积是混在一起的，很难拆分。转换到频域，时域卷积变成频域乘积： $|S(f)| = |E(f)| \times |V(f)|$ 取对数，乘积变成加法： $\log|S(f)| = \log|E(f)| + \log|V(f)|$ 。

做 DCT 变换把那些代表声带振动的快速起伏（高频倒谱系数）抛弃，只提取前 13 阶低频系数。

5. 三角带通滤波（Mel 滤波）

将能量谱通过一组 Mel 尺度的三角形滤波器组，定义一个有 M 个滤波器的滤波器组（滤波器的个数和临界带的个数相近），采用的滤波器为三角滤波器，中心频率为 $f(m)$ 。 M 通常取 22-26。各 $f(m)$ 之间的间隔随着 m 值的减小而缩小，如图所示。



（四）动态时间规整（DTW）算法

同一说话人的不同次发音在语速上必然存在差异,不同时间序列可能仅仅存在时间轴上的位移,这都会导致仅仅计算欧几里得距离不合适。DTW 算法通过非线性动态规划,在时间轴上伸缩,寻找特征序列间的最短归整路径距离。

构建累积代价矩阵 $D(i, j)$, 其状态转移方程为:


$$D(i, j) = d(i, j) + \min[D(i-1, j), D(i, j-1), D(i-1, j-1)]$$

回溯矩阵即可得到消除了时间畸变后的最优对齐距离。

1. 定义

Dynamic Time Warping (DTW) 是一种衡量两个时间序列之间的相似度的方法,主要应用在语音识别领域来识别两段语音是否表示同一个单词。

如下图所示,上下两条实线代表两个时间序列,时间序列之间的虚线代表两个时间序列之间的相似的点。DTW 使用所有这些相似点之间的距离的和,称为归整路径距离来衡量两个时间序列之间的相似性。



2. 计算方法


令要计算相似度的两个时间序列为 X 和 Y , 长度分别为 $|X|$ 和 $|Y|$ 。

归整路径的形式为 $W=w_1, w_2, \dots, w_k$, 其中 $\max(|X|, |Y|) \leq k \leq |X|+|Y|$ 。 w_k 的形式为 (i, j) , 其中 i 表示的是 X 中的 i 坐标, j 表示的是 Y 中的 j 坐标。归整路径 W 必须从 $w_1=(1, 1)$ 开始, 到 $w_k=(|X|, |Y|)$ 结尾, 以保证 X 和 Y 中的每个坐标都在 W 中出现。另外, W 中 $w(i, j)$ 的 i 和 j 必须是单调增加的, 以保证 1 中的虚线不会相交, 定义为:

$w_k = (i, j), w_{k+1} = (i', j'), i \leq i' \leq i+1, j \leq j' \leq j+1$ 最后要得到的归整路径是距离最短的一个归整路径:

最后求得的归整路径距离为 $D(i, j) = d(i, j) + \min[D(i-1, j), D(i, j-1), D(i-1, j-1)]$, 使用动态规划来进行求解:

DTW : 动态时间规整对齐




四、实验代码设计

实验代码已作为附件发送。

实验基于 MATLAB R2025a 进行。

DTW 算法比对材料为同学的录音样本。识别语音为“浙江大学”“求是创新”“信电学院”“信号系统”，并储存在 \...\ref_audio\ 文件夹下，建立四个子文件夹储存对应词条。考虑到 MATLAB 对中文支持较好，直接采取中文命名。



每个词条文件夹下，存放若干个用于比对的音频，这些音频从八个音频中选取而来，选取的标准是：吐字清晰、背景无杂音、语速适中，便于作为参考。最终，选取了五份参考样本，如下图所示。

- CZY-信号系统.mp3
- GJR-信号系统.m4a
- GZ-信号系统.m4a
- WSJ-信号系统.m4a
- XWK-信号系统.m4a

另外三份音频文件可做测试集。

本代码支持各类音频文件的识别，会在预处理中修改为.wav 格式。

本代码还支持语音录入。

(一) 代码实现细节

1. 前端信号清洗

功能目标： 将物理声波采集并转化为数字信号。

多端输入与重采样防护：

系统通过 `audiorecorder(fs, 16, 1)` 实时接管麦克风，或通过 `audioread` 导入本地文件。

当用户导入非标准采样率音频（如 44.1kHz 的音乐或 48kHz 的手机录音）时，代码会强制触发 `resample(audio_tmp, fs, fs_read)`，将其统一下采样到 16kHz 标准频率。这保证了后续频域分析（如 FFT 频点映射）的物理分辨率基准一致。

能量检测：

在 `remove_silence` 核心函数中，系统摒弃了盲目处理整段录音的粗放方式。它将音频切分为短帧，计算每一帧的时域能量 `sum(frames.^2, 1)`。

通过设定动态的绝对能量阈值（最大能量的 3% 且带有底噪下限保护），系统能够精准剥离出真正含有语音的有效片段（Voiced Segments）。这极大地减少了后续 DTW 矩阵的计算维度，并避免了将纯环境白噪音当作语音进行强制匹配的错误。

2. 核心特征提取（MFCC & CMS）

功能目标： 剥离个人音色与信道干扰，提取声学特征。

加窗与非线性频域映射：

特征提取模块 `extract_mfcc_features` 首先对纯净的语音进行分帧（25ms/帧），并乘以汉明窗 `hamming()`，以抑制时域截断产生的吉布斯现象和频谱泄漏。

随后执行快速傅里叶变换（FFT）计算出能量谱，并送入 `mel_filterbank`。利用 20 个非线性分布的三角滤波器，模拟人耳对低频敏感、高频迟钝的听觉掩蔽效应，实现特征降维。

离散余弦变换（DCT）解耦：

对对数梅尔频谱执行 DCT 变换，这是系统最关键的物理信息解耦步骤。它将包含了音高、谐波的基音高频倒谱脉冲抛弃，仅保留前 13 阶低频系数，提炼出代表元音/辅音的声道物理共振峰包络。

倒谱均值相减（CMS - Cepstral Mean Subtraction）：

代码特征提取末尾的 `mfcc_feat = mfcc_feat - mean(mfcc_feat, 1)` 是抵御信道干扰的核心。不同的麦克风设备存在不同的直流偏置和频响衰减，这一步从物理意义上减去了时间维度的常数均值，抹平了硬件信道差异。

3. 动态时间规整（DTW）匹配

功能目标： 消除发音语速忽快忽慢带来的时间畸变，科学计算特征距离。

特征维度的降维与对齐：

在识别核心循环 `for k = 1:length(these_refs_cell)` 中，系统提取测试特征 `test_feat` 与参考库模板 `ref_feat` 逐一对比。

代码在此执行了 API 适配转置：`dtw(test_feat', ref_feat')`。它确保了 13 维的声学特征作为一个不可分割的整体向量，严格在“时间帧（列）”的轴向上进行动态规划，规避了将多个倒谱系数错误拆分为独立时间序列。

规整路径归一化：

原生 DTW 返回的累计代价 `dist` 是原始距离总和，这会导致长音频在比对中天然具有极高的代价劣势。系统利用 `norm_dist = dist / path_len` 将总代价除以最优规整路径的总步数，计算得出每帧平均规整距离。

4. 防下溢与概率映射

功能目标： 将底层的“距离”转化为人类直观的“置信度”，并限制数值范围。

距离到概率的非线性转化：

距离越小，概率越大。代码引入了锐化因子 $\beta = 15.0$ ，计算得分 `scores = -beta × norm_distances`，以放大高相似度模板间的细微差距。

计算数值范围限定：

当测试音频含噪过高时，平均距离可能达到数百。此时直接计算 $e^{(-15 \times distance)}$ 会越过浮点下限，产生分母除零的 NaN 现象。

代码利用 `max_valid_score = max(...)` 和 `scores_shifted = scores - max_valid_score`，强行将最高得分项平移至 0。在维持相对概率空间分布（距离差）完全不变的前提下，最高概率项的分子被钳制为 1，避免数值下溢的可能。

5. 工程调度与内存释放

功能目标：保证系统应对异常交互的反应与存储空间配置。

异步硬件钩子（`CloseRequestFcn`）：

绑定在主界面上的 `@closeFigure` 拦截了用户的暴力关闭操作。即使用户在录音中途点击右上角红叉，系统也会在 GUI 进程销毁前强制发送 `stop(recorder)` 释放声卡底层独占指针，防止系统音频设备锁死。

自动清除临时文件：

引入 MATLAB 高级语法机制 `cleanup = onCleanup(@() delete_temp_file(temp_file))`。无论识别过程中发生了何种致命错误导致 `try-catch` 中断，只要代码跳出当前作用域，转换生成的临时 .wav 缓存文件都会被自动销毁，杜绝僵尸文件挤占磁盘空间。

热更新：

`compute_dir_hash` 函数摒弃了对外部 Java 环境的依赖，将参考目录下所有音频的“修改时间+字节大小”文本拼接为数字指纹。若用户在系统后台静默替换了参考录音文件，系统在下次识别前瞬间便能察觉哈希不匹配，并立刻触发显存特征库重构。

（二）系统运行原理

物理声波 $\xrightarrow{\text{ADC 采样}}$ 一维数字矩阵 $\xrightarrow{\text{VAD 去静音}}$ 有效波段 $\xrightarrow{\text{加窗+FFT+DCT}}$ [N 帧 $\times$ 13 维] 声学特征矩阵

DTW 动态时间规整 $\rightarrow$ 各模板平均匹配代价 $\xrightarrow{\text{Shift-Softmax}}$ 输出最高置信度文本

（三）代码迭代过程（Debug 与优化）

1. 语法与代码结构优化

1.1. MFCC 使用均值压缩导致 DTW 失效

初版代码提取特征后对所有帧取了均值，得到 1×13 向量。整段语音的时序信息（音节先后顺序）被完全丢弃了，导致 DTW 算法退化成了普通的空间距离计算。

解决方案：重构代码，存储完整的 MFCC 帧序列矩阵 $[n_frames \times 13]$ ，使得 DTW 真正发挥时间对齐的功能。

1.2. DCT 变换的维度乱码

在手动实现 MFCC 的代码中，Claude 分析后地指出 `dct(log_mel')` 导致了变换轴向错误。若先转置再 DCT，实际上是在压缩“时间轴”

解决方案：直接对 `log_mel` 进行 `dct`（MATLAB 默认按列运算，即对每帧的滤波器频域压缩），再取前 13 行转置。

1.3. DTW 输入矩阵的转置修正

Claude 指出，MATLAB 的 `dtw(X,Y)` 函数默认“将每一列视为一个时间序列”。如果不做转置直接传入特征，DTW 会把 13 个倒谱系数当作 13 个独立的时间轴规整。

解决方案：将其转置为 $[13 \times n_frames]$ 传入。

1.4. 响度差异影响识别

录音设备的绝对电平差异导致 MFCC 能量系数偏移。

解决方案：摒弃容易放大静音底噪的全局 RMS，采用倒谱均值相减（CMS）：`mfcc_feat = mfcc_feat - mean(mfcc_feat, 1)`，消除信道衰减和硬件电平差异。

2. 浮点运算下溢规避

2.1. DTW 距离未归一化导致失真

DTW 累计距离与音频长度成正比，长音频天然吃亏。

解决方案：获取规整路径步数 `path_len = length(ix)`，引入除法 `dist / path_len`，将距离规范至 1~6 的合理区间。

2.2. Softmax 温度参数不当导致报 NaN

为拉开概率区分度，引入了锐化因子。但在面临高噪声音频时，距离飙升导致数值越过双精度下限被截断为 0，引发结果的 NaN。

解决方案：令 `score_shifted = scores - max{scores}`，钳制最大指数恒为 1。

3. 静音判断与底层调度

3.1. 静音 / 低音量输入被误判为有效语音

原有 RMS 放大将无声片段强行拉高导致误识别。

解决方案：判断原始音频 `raw_rms < 0.01` 则拒绝计算。

3.2. 用户无法中止长时间识别

增加全局 `stop_requested` 标志，在算法循环中定时轮询，允许用户中止识别计算过程。

3.3. 用户关闭窗口时未释放硬件

强退可能导致底层硬件资源锁死。为主图窗设置 `CloseRequestFcn` 钩子，强制在关闭前触发 `stop(recorder)` 销毁声卡硬件指针。

3.4. 临时文件处理

临时文件（`temp/*.wav`）不断积累，长时间运行可能导致磁盘空间占用过多。

解决方案：引入 MATLAB 特有的 `onCleanup` 析构对象，保证哪怕函数异常中断，产生的临时文件也会被立刻回收。

3.5. 更改目录后正确挂载

目录变更回调中同步更新全局 `ref_dir` 并立即触发特征显存刷新。

3.6. 缓存“热更新”失效

用户替换音频但文件名不变时旧缓存不刷新。

解决方案：在生成特征库时计算所有音频的“修改时间”和“大小”拼接成的指纹哈希，每次启动强制对比，实现缓存的安全热更新。

4. GUI 视觉与个性化动态交互体验

4.1. 结果输出格式丑陋

原代码使用 `\n` 直接拼接，被当做字符串变量显示。

解决方案：改用 `sprintf` 生成排版整齐的数据报表输出。

4.2. 个性化背景图与输出

为实现 CC98 背景水印，创建透明 `axes` 放置图片，并将前端编辑框背景设为 'none'，实现“图文堆叠”效果。

4.3. 图片加载后出现坐标轴刻度与边框

`imshow` 后自动生成干扰视觉的边框。

解决方案：封装 `create_clean_axes` 辅助函数，设置所有坐标属性为 'off'，消除渲染残影。

（四）结果展示

第一次启动时会生成参考模板，此后每一次都自动加载该模板而无需重新生成。

```
生成参考模板...
参考模板已保存至 ref_cache.mat
>> |
```

```
从缓存加载参考模板 (ref_cache.mat)
>> |
```

1. 主界面

可以自主选择文件，也可直接录音。在选择文件识别时，可以自主决定是否勾选播放音频，当勾选时，在识别过程中会同步播放该音频。识别过程中，点击“停止”即可中断识别，已经识别过的文件会在缓存中标记其内容，再次识别时无需重新计算，“清除缓存”可以释放之前识别过音频的标记，再次识别同样的音频时，需重新计算。



点击“清除缓存”后，界面提示如下



2. 录音识别模式

录音状态下，当未识别到声音或声音较小时，提示“请提高音量或确保麦克风正常工作”。



正常工作时，会显示对应的 DTW 距离与置信概率，同时主界面“98 娘准备好啦”变为“98 娘听清楚啦”。在识别过程中，会显示“98 娘聆听中”。



3. 文件识别模式

正常情况下输出如下：

可以发现，对于选取的几个样本，DTW 均能较好的识别。

基于DTW的语音识别系统

选择参考目录

开始录音

选择文件

☐ 播放识别音频

停止

清除缓存

当前文件: E:\AAAzju\信号系统\课设\DYJ\DYJ-求是创新.m4a

98娘听清楚啦

识别结果: 求是创新

短语	平均DTW距离	概率
浙江大学	4.07	0.10%
求是创新	3.38	90.65%
信电学院	4.18	0.03%
信号系统	3.61	9.22%

基于DTW的语音识别系统

选择参考目录

开始录音

选择文件

☐ 播放识别音频

停止

清除缓存

当前文件: E:\AAAzju\信号系统\课设\DYJ\DYJ-信电学院.m4a

98娘听清楚啦

识别结果: 信电学院

短语	平均DTW距离	概率
浙江大学	3.08	33.62%
求是创新	3.58	0.23%
信电学院	3.02	65.96%
信号系统	3.60	0.20%

基于DTW的语音识别系统

选择参考目录

开始录音

选择文件

☐ 播放识别音频

停止

清除缓存

当前文件: E:\AAAzju\信号系统\课设\GYX\GYX-信号系统.wav

98娘听清楚啦

识别结果: 信号系统

短语	平均DTW距离	概率
浙江大学	4.92	0.31%
求是创新	4.79	1.05%
信电学院	4.98	0.17%
信号系统	4.34	98.47%



发现几个样本虽然有杂音但整体比较纯净，所以能达到较好的识别效果。同时也发现一些未能识别成功的现象：



CZ 的录音识别失败了，其它的均识别成功。

仔细听过录音之后发现，背景音很嘈杂，导致识别失败。在环境安静时，DTW 识别能有较好的效果。

4. 异常情况处置

在识别 GYX-信电学院样本时，产生输出：

识别结果: 信电学院

短语	平均 DTW 距离	概率
浙江大学	447.54	NaN%
求是创新	447.75	NaN%
信电学院	440.26	NaN%
信号系统	447.30	NaN%

并且所有 32 个样本仅有这一份样本出错, 原因未知, 可能是计算时因为某些因素导致的数据爆炸。为了对此结果进行防护, 新增加了映射 DTW 距离选项, 将所有的距离映射到通常的 1.0~5.0 区间再进行识别, 得到:



总结

至此, 所有的代码优化与调试过程结束, 代码功能正常。

五、DTW 的不足

四- (四)-3 中的噪音环境失真现象, 主要归结于以下几个方面:

1. 噪声直接污染了 MFCC 特征空间

DTW 比较的是两段语音的 MFCC 特征向量的欧氏距离。在安静环境下, MFCC 完美刻画了人声声道的包络形状。当背景噪声加入时, 由于声音在物理上是能量叠加的, 噪声的频谱直接叠加在了语音频谱上。提取出的 MFCC 向量会被严重扭曲, 相当于原来的“几何形状”被完全破坏, 导致匹配失败。

2. VAD 的崩溃

DTW 对语音的“起点”和“终点”极度敏感。在代码中, DTW 的状态转移方程严格要求路径从 (1,1) 走到 (N,M)。安静时, VAD (如能量阈值检测) 能准确切出“信电学院”这四个字的起止时间。噪声一大, VAD 就会把前面的咳嗽声、风声或者哪怕只是大一点的底噪, 错误地识别为语音的开始。这会导致, DTW 被迫把一段长长的“纯噪声帧”去强行对齐参考模板里的“有效语音帧”。这种强行规整会让累积代价爆炸。

3. DTW 缺乏概率泛化能力 (没有抗噪免疫力)

对比现在的深度学习 (DNN) 或隐马尔可夫模型 (HMM), DTW 太死板了。HMM/DNN

是基于大量数据训练出来的概率模型。模型见过各种带噪的声音，知道哪些特征是重要的，哪些是不重要的，它会给噪声赋予极低的权重。DTW 没有经过训练，只是单纯地做物理模板比对。参考模板是在安静环境下录的，测试语音是嘈杂的，DTW 无法分辨出“背景音是无关的”，它会把背景音也当成发音的一部分去硬匹配。

4. 误差无差别累积

在 DTW 的代价矩阵中，每一帧的距离都会被累加到总代价中。哪怕一句话中只有零点几秒的瞬间突发噪声，这几个异常帧产生的距离也会累加到全局距离 $D(N,M)$ 中，导致原本正确的短语得分暴跌，甚至输给其他毫不相干的错误选项。

六、心得与体会

本实验设计目标基本完成，并有一些创意的 idea 作为普通的 GUI 的扩展。

实验结果充分证明，结合“MFCC 特征提取”与“DTW 动态时间规整”的系统能够高度精准地完成低噪环境近场特定短语的识别任务。MFCC 利用 DCT 有效解耦了复杂的声学频域信息，而 DTW 的动态规划状态方程克服了人类发音语速带来的非线性时变畸变。

从使用汉明窗的时频卷积抑制频谱泄漏，到采用对数能量模拟韦伯听觉定理，课本上的非周期信号傅里叶变换（FT）与离散系统频域分析理论在实际代码架构中发挥了根本性的指导作用。

在 debug 与功能优化的过程中，工程系统的生命力在于对边界的防御，开发一个真正能落地的软件系统，面对的不仅是理想的测试数据，更是底噪、浮点数底层精度截断与用户非理性的异常操作等环境。通过在编写历程中定位并解决这些漏洞并添加创意的界面优化，系统不仅有基础的功能，还有个性化的 GUI 界面，个人对信号处理的思维与代码的驾驭能力也获得了提升。